

Applied Mechanistic Interpretability Methods

Henry Brose

Modul: Explainable Artificial Intelligence (Master)
Dozent: Felix Neubürger

Fachhochschule Südwestfalen
10.07.2026



Inhaltsverzeichnis

1	Einleitung	2
1.1	Motivation	2
1.2	Aufbau der Arbeit	2
2	Hintergrund und Grundlagen	2
3	Methodik und Experimente	2
4	Ergebnisse	2
5	Diskussion	2
6	Fazit	2
	Literaturverzeichnis	2



1 Einleitung

1.1 Motivation

1.2 Aufbau der Arbeit

2 Hintergrund und Grundlagen

3 Methodik und Experimente

4 Ergebnisse

5 Diskussion

6 Fazit

Literaturverzeichnis